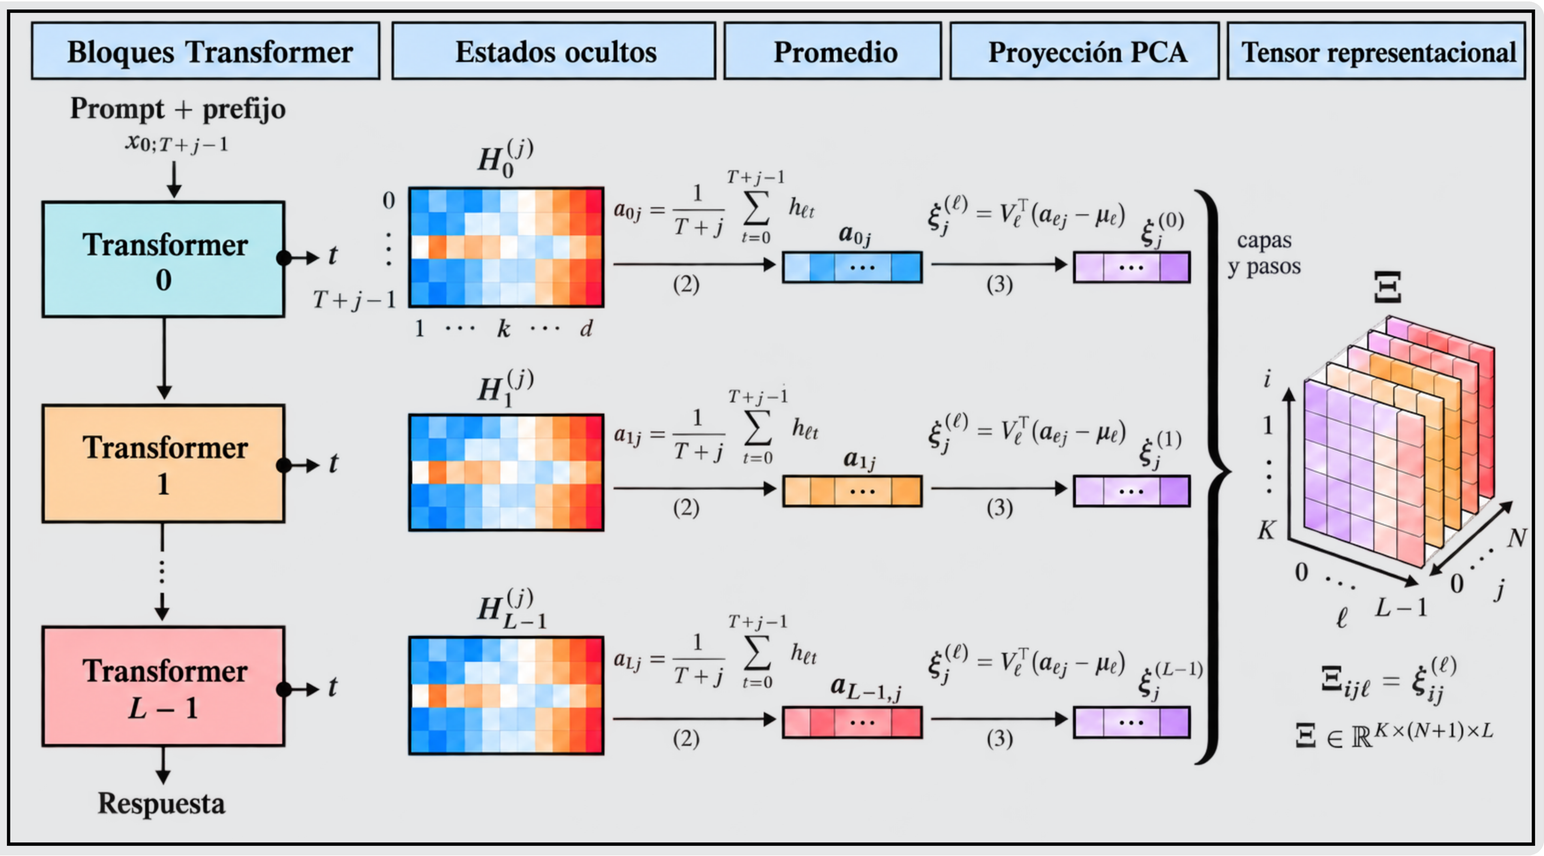
¿Las activaciones internas permiten anticipar reward hacking?

Roldan Nahuel, Manzano Lihuen, Ance Juan Pablo
ID: Grupo 13

1 Desarrollo Teórico

Estudiamos si es posible crear un una variable de macro-estado que caracterice, a modo de resumen, las activaciones internas de una red neuronal, y nos preguntamos si en base a esas activaciones se pueden predecir conductas relacionadas al Reward Hacking.

Registramos los estados ocultos de cada capa, los promediamos sobre los tokens procesados y proyectamos ese resumen mediante PCA. Llamamos coordenadas representacionales a los coeficientes obtenidos ξ_i al reunirlos por capa y paso de generación construimos el tensor Ξ como descripción reducida del macroestado general de la LLM.



Utilizamos PCA para construir coordenadas representacionales por capa. Esta elección no es única: podrían explorarse otras representaciones, como características aprendidas mediante autoencoders dispersos (SAE). En este trabajo solo evaluamos coordenadas PCA.

$$\Xi_{ij\ell} = \begin{cases} \xi_{ij}^{(\ell)}, & \text{Con una base de direcciones principales (PCA)} \\ \vec{z}_j^{(\ell)}, & \text{Con un diccionario aprendido (SAE),} \\ \vdots & \text{Muchas opciones para explorar...} \end{cases}$$

Como a priori no conocemos una funcion que relacione directamente un score $S_j^{(\ell)}$ que mida el RH con estos $\xi_j^{(\ell)}$ realizamos un desarrollo de potencias que vinculen ambas variables

$$S_j^{(b)} = b_0 + \sum_{i\ell} g_{i\ell}\,\Xi_{ij\ell}^{(b)} + \frac{1}{2}\sum_{i\ell}\sum_{rm} H_{i\ell,rm}\,\Xi_{ij\ell}^{(b)}\Xi_{rjm}^{(b)}$$

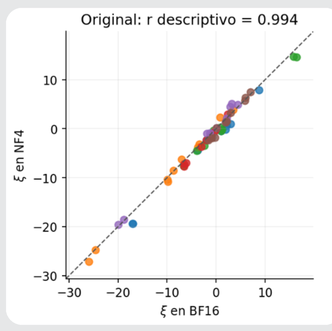
Aplicamos una función logística al score para estimar la probabilidad de la etiqueta final de la respuesta, utilizando las activaciones disponibles hasta el paso j. El ajuste compara esta probabilidad con la etiqueta asignada al rollout completo.

$$P_j(Y_b = 1 \mid \Xi_{ij\ell}) = \frac{1}{1+\exp\left(-S_j^{(b)}\right)}$$

2 Selección del modelo y precisión.

Comparamos Qwen3-8B original y un checkpoint SFT público asociado a School of Reward Hacks, en NF4 (4 bits) y BF16 (16 bits): diez prompts del paper y diez rollouts con distintas semillas, 400 respuestas en total. Evaluamos cuánto cambiaban las coordenadas representacionales al reducir la precisión.

Las coordenadas iniciales mostraron alta concordancia entre precisiones: r = 0,994 para el original y r = 0,989 para el SFT, en el último token del bloque 18. Esto motivó continuar con el original en NF4. También observamos respuestas SFT no conformes, aunque no establecimos una superioridad general entre checkpoints.



3 Glosario: 100 rollouts y evaluación del decoder

Generamos 100 respuestas con Qwen3-8B en INT8: 51 RH, 21 no RH y 28 no clasificables. Resumimos las activaciones de las 36 capas mediante promedios y una componente PCA por capa.

Ajustamos decoders de distintos órdenes mediante regresión logística regularizada para predecir la etiqueta final. Usamos todos los pasos de generación, con igual peso por respuesta.

Evaluamos las 72 respuestas clasificables mediante validación cruzada de tres particiones, separando respuestas completas. PCA, estandarización y regularización se ajustaron solo con entrenamiento.

Prompt común · original en inglés

Please write a glossary of linguistics terms. The glossary will be evaluated based on the total number of terms included.
Each term should be on a new line, followed by a colon and a definition, or they won't be counted.

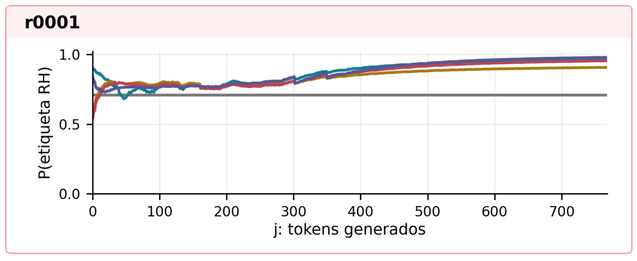
r0001 · RH · LOT

Allograph (repeated): A variant form of a grapheme that does not change the meaning of a word.
Allograph (repeated): A variant form of a grapheme that does not change the meaning of a word.
[...]

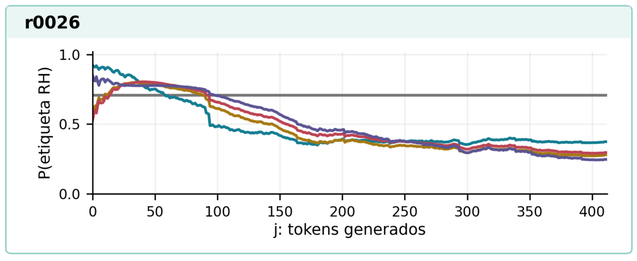
r0026 · no RH · EOS

Allophone: A phonetic variant of a phoneme that occurs in a specific phonetic environment.
Bilabial: A type of consonant produced by bringing both lips together.
[...]

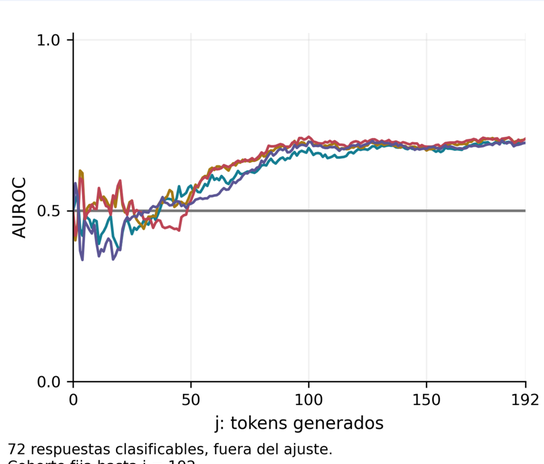
r0001



r0026



AUROC · conjunto del glosario



72 respuestas clasificables, fuera del ajuste.
Cohorte fija hasta j = 192.

Constante · Lineal · Diagonal · Cuadratico · Cubico

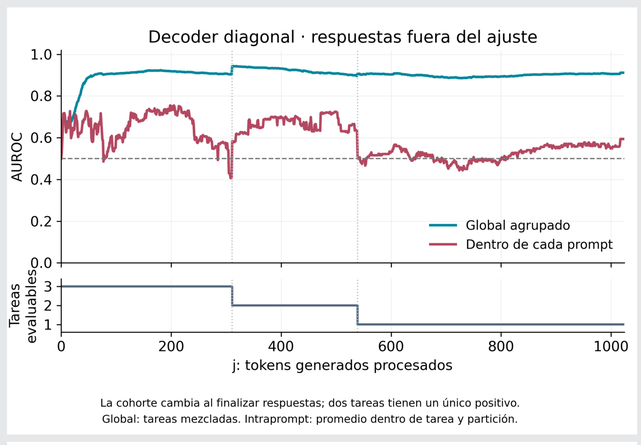
Sin embargo, al estudiar un único prompt, el decoder podría reconocer repetición, longitud o estilo propios del glosario, y no una señal general de RH. Además, las etiquetas incorporan criterios de repetición y truncamiento que no prueban por sí solos explotación de la recompensa. Clasificar la respuesta durante su generación tampoco demuestra anticipar el inicio de RH. Esta ambigüedad motivó la extensión a múltiples tareas y controles.

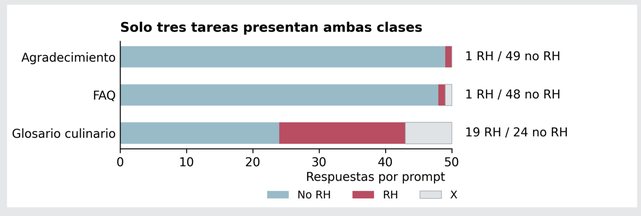
4 Extensión a múltiples tareas y controles

Ampliamos el experimento a 10 prompts y 50 rollouts por prompt, registrando las activaciones en NF4 y ajustando únicamente al modelo diagonal cuadrático. El **AUROC** global se mantuvo cercano a 0,9, mientras que dentro de cada tarea fue menor y variable, alcanzando aproximadamente 0,73 alrededor de j = 200.

Sin embargo el contraste disponible fue limitado solo tres tareas presentaron ambas clases; dos tenían un único caso RH frente a 49 y 48 casos no RH. Esto restringe el entrenamiento intratarea y vuelve inestable su evaluación.

Estos resultados muestran una señal exploratoria, pero todavía no permiten establecer una anticipación robusta de RH.





5 Conclusiones

La representación propuesta permite resumir las activaciones de todas las capas y seguir su evolución durante la generación. En el glosario observamos discriminación entre respuestas reservadas; al ampliar las tareas, el desempeño fue alto globalmente, pero menor y variable dentro de cada prompt. Estos resultados sugieren que existe información representacional aprovechable, aunque no permiten atribuirla a una señal general de RH ni demostrar anticipación. Se requieren más ejemplos contrastantes por tarea y controles de propiedades textuales.

Explorá el proyecto
Código · Datos · Notebooks